

EvalCall 决赛提交与现场清单

2026-07-15 提交 · 10 分钟路演 + 10 分钟答辩

FINAL	决赛提交版 · 2026-07-14 · 所有数字以仓库正式运行产物为准
-------	--------------------------------------

截止：2026-07-15 路演：10 分钟 PPT + Demo；问答：10 分钟

一、正式提交

- ☐ 上传最终 PPT：EvalCall答辩稿-评审高分终版-20260714.pptx
- ☐ 上传方案设计文档：EvalCall方案设计文档-最终版-20260714.pdf（同时保留 DOCX）
- ☐ 提交 GitHub：https://github.com/kaijie0074-art/evalcall
- ☐ 打开仓库默认 main，确认首页为最新版且快速开始可见
- ☐ 打开公网 Demo：https://kaijie0074-art.github.io/evalcall/app.html

二、现场主设备

- ☐ 安装可打开 PPT、DOCX、HTML 的软件
- ☐ 登录并验证 Codex CLI 后端
- ☐ 启动本地服务并确认健康检查显示后端可用
- ☐ 浏览器打开 http://127.0.0.1:8765/app.html
- ☐ 预选“配送时间改约”，停留在第一步
- ☐ PPT 使用演讲者模式，10 分钟稿放在主讲人可见设备
- ☐ 关闭通知、聊天软件弹窗、系统更新和休眠
- ☐ 接通电源，准备 HDMI / Type-C 转接头和鼠标

三、三级备份

1. 本地实时服务 + 已验证产物模式。
2. GitHub Pages 公网工作台 + 正式报告 HTML。
3. PPT 第 5—7 页 + 本地报告截图，在网页异常时继续讲述。

四、路演数字核对

- 配送改约 v1: 10 通、21 项、210 条判断、3/10 打回、履约 40%、P0 3/10、平均分 62.5。
- 配送改约首要根因：外呼模型，中置信；NA 9%，裁判分歧 0%，模型归因分 48。
- 配送改约 v2: 门禁“可上线”、P0 0/10、履约 40%、平均分 91.4；同一用户输入、SOP、Checklist、Judge 正常重评，不手改 judgments。
- 原生 diff: 6 项改善、1 项 style 退化待复测；证据见 `runs/t02_delivery_fixedusers_regression_20260714/comparison.json` 与 `native_diff.json`。
- 低延迟直播：SOP 可行性 0/100、4 项高严重度问题、首要根因任务指令。
- 裁判校准：32 case、165 真值、153 正确、92.73%；P0 11/11；style 70%。

五、禁止错误表述

- 不把合成分支描述为真实生产录音。
- 不把黄金集准确率描述为线上准确率。
- 不把中置信归因描述为严格因果证明。
- 不把缓存结果描述为刚刚现场运行。
- 不承诺未经测算的具体降本金额。

六、当天安排

- 7 月 15 日 17:00：参观美团。
- 7 月 15 日 18:00：现场抽签决定次日顺序。
- 酒店：北京朝阳望京科技苑亚朵酒店；两人一间，随机分配，含早餐。