

EvalCall 决赛路演演讲稿（10 分钟正式版）

10 分钟 PPT + 现场 Demo · 计划 9 分 30 秒，预留 30 秒机动

FINAL	决赛提交版 · 2026-07-14 · 所有数字以仓库正式运行产物为准
-------	--------------------------------------

使用场景：10 分钟 PPT 介绍 + 现场 Demo，随后 10 分钟评委问答。主讲目标：让评委清楚理解 EvalCall 评的是外呼模型，SOP 是评分依据，用户模拟器是测试工具，归因与校准是可信度保障。计划用时：9 分 30 秒；预留 30 秒机动。

路演总路线

- 1. PPT 第 1—4 页：问题、角色和产品主线（2 分 20 秒）
- 2. 工作台六步主演示：配送时间改约（4 分钟）
- 3. PPT 第 5—7 页：结果、可信度和对照案例（2 分 10 秒）
- 4. PPT 第 8 页：价值收束（1 分钟）

0:00—0:40 | PPT 第 1 页：开场

大家好，我们做的是 EvalCall，一个自动测试并评估外呼模型任务指令遵循效果的平台。

今天的外呼模型已经可以流畅对话，但“会说话”不等于“能完成业务任务”。在合同通知、配送改约、骑手招聘等场景中，漏掉一句必要告知、错误承诺一次结果，或者没有用户在用户拒绝时及时退出，都可能导致模型无法上线。

EvalCall 要回答的不是“这段对话听起来像不像人”，而是一个更直接的问题：这个外呼模型是否按要求把任务完成了，能不能放心上线。

0:40—1:20 | PPT 第 2 页：把四个角色摆正

在我们的系统里，被评对象只有外呼模型。

SOP 是评分依据，定义模型应该怎么做；用户模拟器是官方要求的测试工具，负责生成可控、可覆盖的用户反应；对话日志是测试过程数据；SOP 诊断、裁判校准和根因归因，则负责防止错误归责。

这一点很重要：EvalCall 不是 SOP 检查器。我们的核心交付始终是外呼模型评测报告，其他能力都是为了让这份报告可信。

1:20—2:00 | PPT 第 3 页：六步真实链路

整个评测流程分成六步。

第一步配置任务，第二步把 SOP 编译成评分标准，第三步测试外呼模型，第四步输出模型评测报告，第五步分析失败来自模型、SOP、裁判还是测试数据，第六步生成对应优化和回归计划。

前三步解决“怎么测”，第四步回答“能不能上线”，后两步回答“为什么失败、下一步改什么”。所以第四步是产品的核心交付终点。

2:00—2:20 | PPT 第 4 页：进入 Demo

下面我用“配送时间改约”演示完整流程。

为保证现场稳定，主演示使用仓库内同一套真实接口跑出的已验证产物，页面会明确标注“缓存结果·已验证产物”；系统也支持本地实时运行，两种结果不会混淆。现在展示的是可操作产品，不是录屏。

2:20—2:50 | 工作台第 1 步：配置测试任务

【操作】打开工作台，选择“配送时间改约”，进入“配置测试任务”。

第一步确定评谁、依据什么任务指令评，以及用什么方式测试。

这里有两种入口：一种是模拟测试模式，让用户模拟器与被测模型自动对话；另一种是已有日志质检模式，直接导入历史对话。系统同时记录 SOP、对话、Checklist 和模型版本哈希，后续每个数字都可以追溯到同一批输入。

2:50—3:20 | 工作台第 2 步：建立评分标准

【操作】点击“建立评分标准”。

系统把自然语言 SOP 编译为机器可执行的 Checklist。L0 是通用安全红线，L1 是当前业务的流程和约束。

这个主演示批次最终冻结为 21 个检查点，其中 5 个是 L0 通用安全规则、16 个是 L1 业务规则。每条检查点都保留来源和严重度，后续不同模型版本使用同一把尺子，避免为了让分数好看而更换标准。

3:20—4:00 | 工作台第 3 步：测试外呼模型

【操作】点击“测试外呼模型”。

用户模拟器会扮演不同类型的用户，包括同意、拒绝、忙碌、隐私顾虑和异常情况，主动触发流程分支。系统不仅统计测试了多少通，还统计哪些规则已经触达、哪些规则没有覆盖。

现场这批数据共 10 通，其中模拟器生成与显式标记的分支夹具共同覆盖关键场景；合成分支都有明确标记，不会冒充真实生产录音。

4:00—5:15 | 工作台第 4 步：输出模型评测报告

【操作】点击“输出模型评测报告”，停留并指向门禁、履约率、P0、覆盖率和报告链接。

这是 EvalCall 的核心交付。

本轮共评测 10 通对话，依据 21 个检查点产生 210 条逐项判断。最终 3 通被打回，履约率 40%，3 通触发 P0，平均分 62.5，因此门禁结论是“打回”。

报告不仅给总分，还给出关键失败、规则覆盖率、逐项结论和原始对话证据。也就是说，评委或业务人员可以从“模型不能上线”一路下钻到“哪一通、哪一条规则、哪一句对话导致了这个结论”。

【操作】打开一次正式报告，展示一条带证据的失败项，然后返回工作台。

这里需要如实说明：本批结果中 NA 占比为 9%，裁判分歧率为 0%；自动归因仍是确定性信号归纳，不把它包装成严格因果证明。

5:15—5:55 | 工作台第 5 步：分析失败原因

【操作】点击“分析失败原因”。

发现失败后，系统不会直接把责任推给模型。归因会同时纳入通话打回率、履约率、P0 触发率、关键流程失败率、严重度、SOP 体检、NA 和裁判分歧。

这个案例里，打回率 30%、P0 触发率 30%、履约率 40%，关键流程失败率 25.4%；SOP 没有高严重度问题，裁判分歧为 0%。因此首要根因是外呼模型，中置信，同时保留“归因不是因果证明”的限制。

5:55—6:20 | 工作台第 6 步：优化与同尺回归

【操作】点击“生成优化与回归计划”。

因为首要根因在模型，第六步生成的是模型和对话策略优化，而不是修改 SOP。优化后返回第三步重新测试，SOP、Checklist 和 10 通用用户输入哈希都保持不变。

现场展示的 v2 不是手工改分：系统逐字回放同一批用户轮，只替换被测策略输出，再交给正常 Judge 重评；`judgments_modified=false`。只有这样，下一轮结果提升才能归因于模型策略，而不是偷偷换了一把更宽松的尺子。

实际结果是：v1 门禁“打回”、P0 3 通、履约率 40%、平均分 62.5；v2 门禁“可上线”、P0 归零、履约率仍为 40%、平均分升到 91.4。原生 diff 显示 6 项改善，同时有 1 项 style 从 pass 变为 fail，标记为“需复测确认”。我保留这条退化，因为成熟评测不只展示好消息。

6:20—7:05 | 对照案例：系统不会什么都怪模型

【操作】切换“低延迟直播升级”，直接进入第五步。

为了证明系统不会什么问题都归责给模型，我们再看一个对照案例。

这份任务指令的可行性体检为 0 分，包含 4 项高严重度问题，例如回复字数上限与参考话术直接冲突，也缺少用户持续拒绝时的退出分支。因此，即使模型表现也很差，首要根因仍然是 SOP 或任务指令，模型归因会因为混杂信号而降级。

对应的修复动作也不同：先由业务 owner 修 SOP，重新编译 Checklist，再进行测试；新旧评分尺不直接做模型能力对比。

7:05—7:55 | PPT 第 6 页：裁判也要考试

【操作】返回 PPT 第 6 页。

自动评测本身也可能出错，所以我们给裁判建立了黄金集校准。

在当前 32 个 case、165 个已知真值上，指定模型和提示词条件下的整体准确率为 92.73%，11 个 P0 fail 全部检出；但 style 类型只有 70%，12 个错判的平均自报置信度仍然达到 96.25%。

因此我们不把模型自信当成正确：高风险、NA、规则冲突和分裂票会进入人工复核。上述校准结果只描述这套黄金集，不外推为线上准确率。

7:55—8:35 | PPT 第 7 页：两类根因，两条闭环

配送改约案例的首要根因是外呼模型，动作是保持 SOP、Checklist、Judge 和用户输入不变，返回第三步改模型、同尺回归。实际 v2 已从“打回”变为“可上线”，P0 3→0，平均分 62.5→91.4，履约率 40% 不退化。

低延迟直播案例的首要根因是 SOP，动作是回到第二步修指令、重建评分尺。

这正是根因归因的价值：不仅发现失败，还避免让错误的人修改错误的东西。

8:35—9:30 | PPT 第 8 页：价值收束

对模型团队，EvalCall 把上线前的人工抽检变成可重复的自动化回归；对业务团队，它直接输出模型能不能上线以及失败在哪里；对管理者，它提供跨版本可比较、可审计的质量依据。

它可以用于配送通知、合同告知、骑手招聘、营销外呼和客服回访等所有要求模型严格遵循任务指令的场景。

EvalCall 最终解决的不是“让模型更会说”，而是让企业能够证明：这个模型是否真的按业务要求完成了任务，能不能放心上线；如果不能，下一步究竟该改什么。

谢谢各位评委。

现场操作纪律

1. 主设备提前启动本地服务，页面保持在“配送时间改约”第一步。
2. 主演示不启动整批新评测，使用明确标注的已验证产物，避免等待模型推理。
3. 只打开一次正式报告，不展开超过一个失败项。
4. 第四步至少停留 60 秒；第二步和第六步不要讲成产品主线。
5. 公网页面、正式报告 HTML 和 PPT 第 5—7 页分别作为一级、二级、三级备用。
6. 剩余 30 秒时直接跳到结尾，不再切换对照案例。