

EvalCall 决赛答辩问答预案（10 分钟）

先结论 · 再证据 · 最后边界 · 单题 30—60 秒

FINAL

决赛提交版 · 2026-07-14 · 所有数字以仓库正式运行产物为准

回答结构：先用一句话给结论，再给可核验事实，最后说明适用边界。单题控制在 30—60 秒。

一、产品定位

Q1：你们和普通的大模型打分器有什么区别？

普通打分器通常直接让模型给一个整体印象分；EvalCall 先把任务指令编译为可追溯 Checklist，再由用户模拟器或已有日志产生测试数据，逐检查点给出证据化判断，最终输出门禁、履约、P0、覆盖率和失败归因。每个运行还保存 SOP、Checklist、对话和模型版本哈希，因此结论可以复跑和审计。

Q2：这不是不是一个 SOP 检查器？

不是。被评对象只有外呼模型，第四步模型评测报告是核心交付。SOP 诊断只在解释低分时检查“尺子本身是否有问题”，避免把不可能执行的指令错误归责给模型。

Q3：为什么要做失败归因？发现模型失败还不够吗？

不够。同一个低分可能来自模型、SOP、裁判或测试数据。如果根因判断错，团队会修改错误的对象，甚至出现“换了评分尺以后证明模型变好”的循环论证。EvalCall 根据根因把回归导向第二步或第三步，并要求同尺对比。

二、用户模拟器与数据

Q4：用户模拟器真的能代表真实用户吗？

模拟器不声称完全复刻真实话务分布，它的价值是系统性覆盖 Persona、拒绝、忙碌、隐私顾虑和异常分支。平台同时支持导入已有日志质检；模拟测试用于补覆盖，真实日志用于贴近生产分布，两者互补。

Q5：你们的演示数据是真实生产数据吗？

数据来源会逐条标记。官方、脱敏、用户模拟器生成和合成分支夹具不会混写。配送改约的 10 通包含模拟器数据和显式标记的分支夹具，不能描述为 10 通真实生产录音；真实招聘案例只说明“真实生产 SOP”，也不外推为完整线上话务分布。

Q6：如何衡量测试是否充分？

系统统计已触达检查点、未触达检查点、Persona 分布和关键流程覆盖，不把“跑了很多通”直接等同于充分。覆盖率用于发现测试盲区，不单独作为模型上线依据。

三、裁判可信度

Q7：用大模型评大模型，怎么保证裁判没有胡判？

我们采用证据引用、规则线索与 LLM 语义复核、NA、分歧和人工复核队列，并用已知真值黄金集测试裁判。在当前 32 case、165 真值上整体准确率为 92.73%，P0 fail recall 为 11/11；但 style 只有 70%，所以我们不会宣称裁判可以完全替代人工。

Q8：92.73% 可以直接理解为线上准确率吗？

不可以。它只适用于指定模型、提示词、票数和这套黄金集。线上仍需持续抽检、漂移监控和独立 holdout；演示中必须同时披露类型短板。

Q9：模型自己给的 confidence 有用吗？

只能用于复核排序，不能证明正确。当前黄金集上 12 个错判的平均自报置信度仍为 96.25%，所以可靠性必须来自真值校准、混淆矩阵、P0 recall 和人工裁决。

Q10：规则匹配会不会关键词误杀？

规则轨只提供高置信线索，不独立定罪。最终需要结合说话人、上下文和 LLM 语义复核；规则与 LLM 冲突会显式记录并进入人工复核。

四、归因与主演示结果

Q11：为什么配送改约案例归因给外呼模型？

同一批固定输入下，10 通中 3 通打回、履约率 40%、P0 触发率 30%、关键流程失败率 25.4%，模型失败信号明确；SOP 没有高严重度问题，裁判分歧率为 0%，因此首要根因是外呼模型、中置信。归因仍是确定性信号归纳，不宣称严格因果证明。

Q12：为什么低延迟直播案例归因给 SOP？

该 SOP 的可行性体检为 0/100，并有 4 项高严重度问题，包括字数约束与参考话术冲突、明确拒绝后缺少退出分支。更强的指令故障会使模型归因降级，所以先修 SOP，再重建 Checklist。

Q13：根因算法是不是人工写规则硬凑出来的？

归因是确定性信号归纳，不包装成因果证明。输入包括打回率、履约率、P0、关键流程失败、严重度、SOP 体检、NA、裁判分歧和 Persona 集中度；每个分支都有自动化测试。低、中置信仍需人工确认。

Q14：你们真的改了模型并同尺复测了吗？

做了。v1 与 v2 使用同一批 10 通用户输入，并锁定相同的 `instruction_hash`、`checklist_hash` 和 `judge_policy_hash`；只替换被测策略输出，再由正常 Judge 重评，`judgments_modified=false`。结果从“打回”变为“可上线”，P0 3→0，履约率维持 40%，平均分 62.5→91.4。原生 diff 同时披露 6 项改善和 1 项 style 退化待复测。

五、工程、部署和商业价值

Q15：现场展示的是缓存，算不算真正的 Demo？

它是可操作产品，不是视频。缓存模式复用同一套真实接口产生并保留在仓库中的已验证产物，页面明确标注；本地实时模式会调用后端处理自定义材料。现场使用已验证产物是为了避免长时间模型推理，但不会把缓存冒充刚刚运行的结果。

Q16：如果模型后端不可用怎么办？

健康检查会验证真实后端能力，而不只检查服务进程。内置样例可以复用已验证产物；自定义材料后端不可用时会给出准确错误，不返回虚假的健康分或空报告。公网静态页、正式报告 HTML 和 PPT 是分级备份。

Q17：如何接入企业现有系统？

已有日志可以通过 JSONL、JSON、CSV、TXT 或 Markdown 进入适配层；被测模型和裁判后端独立配置。输出包括 HTML 报告、JSON 汇总、逐项 judgments、manifest、telemetry 和人工复核队列，可接入发布门禁或质量平台。

Q18：数据安全如何保证？

系统默认对手机号、身份证、邮箱、银行卡、订单号和地址进行结构化遮罩，遥测不保存 prompt 原文。是否允许真实数据发送到第三方模型仍由数据 owner 决定，生产部署可以选择内网模型后端。

Q19：能节省多少成本？

当前没有可靠的人工抽检成本和真实生产量基线，因此不宣称具体节省金额。可以确认的是：Checklist 编译、批量逐项判定、证据聚合、复核队列和版本回归已经自动化；正式 ROI 需要结合企业的单通抽检时长、抽检比例和调用成本测算。

Q20：你们的创新点是什么？

第一，把自然语言任务指令编译成可追溯的机器评分尺；第二，用覆盖驱动的用户模拟器主动触发失败分支；第三，不只给分，还给上线门禁和四类根因；第四，用版本哈希和同尺回归避免循环论证；第五，对裁判本身建立黄金集校准和人工复核。

Q21：如果继续做，下一步是什么？

第一，用更多真实脱敏日志扩展任务分布；第二，由独立质检人员维护 sealed holdout；第三，接入真实目标模型 API 做同一 SOP 下多版本对比；第四，把评测门禁接入模型发布流水线；第五，针对高 NA 和 style 短板持续校准裁判。

六、不要说错的数字

数字	正确口径	禁止表述
10 通	配送改约主演示的正式评测批次	10 通真实生产录音
21 项 / 210 条	21 个冻结检查点 × 10 通逐项判断	210 通电话
履约 40%	v1 固定演示批次的任务履约率	线上模型整体履约率
P0 3/10	v1 固定批次中 3 通触发 P0 门禁	线上所有 P0 均能发现
92.73%	指定黄金集、模型和提示词下的裁判准确率	线上裁判准确率
P0 11/11	黄金集中的 11 个 critical fail 全部检出	生产零漏判
首要根因 target_model	确定性信号归纳，中置信，需人工复核	已完成严格因果证明